

المحتويات

2	تشخيص أعطال المحركات المتزامنة ذات المغناطيس الدائم (PMSM) باستخدام الشبكات العصبية الالتفافية على صور المخططات الطيفية الموجية
2	الملخص
3	جدول المحتويات
4	1. مقدمة
4	1.1 الدافع
4	1.2 الهدف
5	1.3 المساهمات
5	2. المحركات المتزامنة ذات المغناطيس الدائم (PMSM) وأعطاها
5	2.1 مبدأ العمل
6	2.2 BLDC مقابل PMSM
6	2.3 أنواع الأعطال الشائعة
7	2.4 لماذا التيار والاهتزاز
7	3. خلفية في معالجة الإشارات
8	4. تحويل الموجيات والمخططات الطيفية
8	4.1 من الجيوب إلى الموجيات
8	4.2 تحويل الموجيات المستمر
9	4.3 المخطط الطيفي
9	4.4 لماذا المخططات الطيفية للشبكات العصبية الالتفافية
10	5. الشبكات العصبية الالتفافية
10	5.1 ما هي الشبكة العصبية الالتفافية
10	5.2 الطبقات
11	5.3 لماذا الشبكات العصبية الالتفافية (وكُلّفها)
11	6. إعداد البيانات
11	6.1 مصادر الإشارة
12	6.2 الفئات
12	6.3 الاستيعاب والتقطيع
13	6.4 توليد المخططات الطيفية
13	6.5 تقسيم تدريب / تحقق / اختبار خالٍ من التسرب
13	6.6 عدم توازن الفئات والموازنة
14	7. نموذج الشبكة العصبية الالتفافية والتدريب
14	7.1 البنية المرجعية (Baseline)
14	7.2 بنية الاندماج
14	7.3 إعداد التدريب
15	7.4 الإقران للاندماج
15	8. النتائج والتحليل
15	8.1 نتائج القناة الواحدة والاندماج
16	8.2 المناقشة
16	8.3 أهمية المقياس الصحيح

17	8.4 القيد الرئيسي
17	9. تجارب التحسين
17	9.1 أثر موازنة الفئات
17	9.2 أثر حجم صورة المخطط الطيفي
18	9.3 أثر حجم مجموعة التدريب (كمية البيانات)
19	9.4 أثر عمق الشبكة (عدد الطبقات)
20	9.5 أثر بنية النموذج (تحسين الشبكة)
20	9.6 هل تساعد البيانات المولدة؟ (التدريب المسبق الاصطناعي والتعزيز)
21	9.7 ضوابط فرط التخصيص
22	10. الاستنتاجات والعمل المستقبلي
22	10.1 الاستنتاجات
22	10.2 القيود
22	10.3 العمل المستقبلي
23	11. المراجع
23	الملحق A - إعادة إنتاج النتائج
24	الملحق B - الضبط الأساسي (config.yaml)
25	الملحق C - تخطيط المستودع
25	الملحق D - مخطط المانيفست (data/manifest.csv)
25	الملحق E - جرد الاختبارات (38 اختباراً)
25	الملحق F - تدقيق مجموعات البيانات

تشخيص أعطال المحركات المتزامنة ذات المغناطيس الدائم (PMSM) باستخدام الشبكات العصبية الالتفافية على صور المخططات الطيفية الموجية

جامعة حلب - كلية الهندسة الكهربائية والإلكترونية قسم هندسة الميكاترونكس

تقرير الندوة البحثية

إعداد الطالبين: ملهم فتنة، محمد زين قباني إشراف: م. سعد المصطفى السنة: السنة الرابعة

الملخص

تعدّ المحركات المتزامنة ذات المغناطيس الدائم (PMSMs) القوة المحركة لأنظمة القيادة الكهربائية الحديثة - كالمركبات الكهربائية، والروبوتات، وأنظمة المؤازرة (servo) الصناعية، ومشغلات الفضاء الجوي - وذلك بفضل كفاءة قدرتها العالية،

وكفاءتها المرتفعة، وقابليتها الممتازة للتحكم. وهي، كسائر الآلات الكهربائية، عُرضة للأعطال، ويأتي في مقدمتها شيوعاً وخطورةً القِصَر الكهربائي بين لَقَات ملف العضو الثابت (inter-turn short winding stator (circuit: وهو عدد قليل من اللَقَات المقصورة التي تتفاقم، إن لم تُكتشف، لتتحوّل إلى عطل كارثي في الملف خلال دقائق. ولهذا فإنّ الكشف المبكر والآلي عن مثل هذه الأعطال ذو قيمة عملية كبيرة.

يعرض هذا التقرير خط معالجة (pipeline) متكاملًا وقابلًا لإعادة الإنتاج خاص بـ تشخيص أعطال المحركات المتزامنة ذات المغناطيس الدائم (PMSM)، إذ (i) يجمع إشارتي تيار المحرك واهتزازة، و(ii) يحوّل نوافذ إشارة قصيرة إلى صور مخططات طيفية موجية مبنية على تحويل المويجات المستمر (CWT) scalogram (images)، و(iii) يصنّف تلك الصور باستخدام شبكة عصبية التلافيفية (CNN). ويحوّل هذا النهج مشكلة سلسلة زمنية أحادية البعد إلى مشكلة تُعرّف على الصور ثنائية البعد، ما يتيح للشبكة العصبية التلافيفية تعلّم بصمات الأعطال آلياً بدلاً من الاعتماد على سمات مصمّمة يدوياً.

نقّذ خط المعالجة من بدايته إلى نهايته بلغة Python (مع مسار بديل بلغة MATLAB) وهو مشمول بـ 38 اختبار وحدة (unit tests) وتكامل مستمر (continuous integration)، ودُرّب وقِيّم على مجموعة بيانات أعطال العضو الثابت الحقيقية PMSM KAIST. وعلى تسجيلات مُتَجَزّة، (held-out) تفصّل المخططات الطيفية للاهتزاز بين المحركات السليمة وتلك المصابة بالعطل بين اللَقَات بدقة متوازنة (balanced accuracy) قدرها 1.00، في حين تُحقّق المخططات الطيفية للتيار 0.69 فقط - وهي نتيجة واضحة ومنطقية فيزيائياً تُظهر أنّ الاهتزاز يحمل بصمة عطل بين اللَقَات أقوى بكثير من تيار العضو الثابت عند مستويات شدة العطل المتاحة. ونقدّم جميع النتائج بالدقة المتوازنة (balanced accuracy) ومقياس macro-F1 (بدلاً من الدقة الخام) لأنّ مجموعة الاختبار غير متوازنة الفئات، ونحن صريحون بشأن القيد الرئيسي للبيانات العامة: لا يوجد سوى أربعة تسجيلات سليمة مميّزة، ومن ثمّ لا يمكن بعدُ ضمان تعميم نتيجة الاهتزاز المثالية ضماناً كاملاً.

جدول المحتويات

1. مقدمة
2. المحركات المتزامنة ذات المغناطيس الدائم (PMSM) وأعطالها
3. خلفية في معالجة الإشارات
4. تحويل المويجات والمخططات الطيفية
5. الشبكات العصبية التلافيفية
6. إعداد البيانات
7. نموذج الشبكة العصبية التلافيفية والتدريب
8. النتائج والتحليل
9. تجارب التحسين

1. مقدمة

1.1 الدافع

تعدّ مراقبة الحالة وتشخيص أعطال الآلات الكهربائية حجر الزاوية في الصيانة التنبؤية. فنظام القيادة القادر على التعرف على تدهوره الذاتي يمكنه تحذير المشغل، أو تخفيض أدائه ذاتياً، أو إطلاق إيقاف مُتحكّم به قبل أن يتحوّل عطل بسيط إلى عطل مدمر. وبالنسبة للمحركات المتزامنة ذات المغناطيس الدائم، تكون المخاطر الاقتصادية والمتعلقة بالسلامة مرتفعة: فهي تُستخدم في الجبرّ (المركبات الكهربائية)، وفي الروبوتات الجراحية والصناعية، وفي مشغلات الطائرات، وفي أنظمة ضبط ميل (pitch) عنفات الرياح، حيث يكون الفشل غير المخطط له مكلفاً أو خطيراً.

تعتمد طرائق تشخيص الأعطال التقليدية على سمات مصممة بخبرة بشرية - مثل تتبع ساعات توافقية (harmonic) محددة في طيف تيار العضو الثابت (تحليل بصمة تيار المحرك، Analysis، Signature Current Motor، MCSA) وهذه الطرائق قوية لكنها هشّة: فهي تُتطلب من الإنسان أن يعرف مسبقاً أيّ تردد يجب مراقبته، وتندهور عند تغيير ظروف التشغيل (السرعة، الحمل). أما التعلّم العميق (deep learning) الحديث فيقدّم بديلاً: إذ يمكن للشبكة العصبية الالتفافية تعلّم السمات ذات الصلة مباشرةً من البيانات، شريطة عرض البيانات بصيغة تستطيع الشبكة استثمارها. والفكرة المحورية لهذا المشروع هي عرض إشارات المحرك على هيئة صور زمنية-ترددية (time-frequency images) (مخططات طيفية)، تكشف بصمات الأعطال على هيئة أنماط بصرية تُعدّ الشبكة العصبية الالتفافية مثالية للتعرف عليها.

1.2 الهدف

المهمة الرئيسية المُسنّدة لهذه الندوة هي:

تصميم نموذج قائم على الشبكة العصبية الالتفافية (CNN) يحلّل صور المخططات الطيفية الموجية المنتجة من إشارات المحرك المتزامن ذي المغناطيس الدائم (PMSM) بهدف تصنيف حالات التشغيل والكشف عن الأعطال.

وعلى نحو ملموس، يجب على المشروع: دراسة النظرية ذات الصلة؛ والحصول على إشارات المحرك المتزامن ذي المغناطيس الدائم (التيار/أو الاهتزاز) في ظل حالات تشغيل مختلفة؛ وتطبيق تحويل الموجات المستمر (CWT) لتوليد صور المخططات الطيفية منظمّة حسب الفئة؛ وبناء وتدريب شبكة عصبية التفافية تصنّف هذه الصور؛ وأخيراً اختبار النموذج وتحليله وتحسينه. أما المخرجات فهي: مجموعة بيانات صور موسومة، وشيفرة تدريب، ونموذج CNN نهائي، وأشكال نتائج، وهذا التقرير، وعرض

تقديمي مرافق.

1.3 المساهمات

إضافةً إلى المتطلبات الدنيا، يقدم هذا العمل ما يلي:

- خط معالجة (pipeline) بلغة Python قابل لإعادة الإنتاج بالكامل وخالٍ من الاعتماد على MATLAB، مُدار بملف ضبط (configuration) واحد ومانيفست (manifest) يربط كل مقطع إشارة بخطه الطيفي وتسميته وتقسيمه البياني.
- استخدام مجموعة بيانات عامة حقيقية بمعدل أخذ عينات مرتفع (KAIST) ذات قناتي إشارة (التيار والاهتزاز معاً)، إضافةً إلى مولد بيانات اصطناعية وشيفرات محاكاة MATLAB كمصادر إشارة بديلة.
- تقسيم بيانات إلى تدريب/تحقق/اختبار خالٍ من التسرب (leakage-free) وجمع حسب التسجيل، ومعالجة مبدئية صارمة لـ عدم توازن الفئات (class imbalance) (وهي أهم قضية عملية تتعلق بالبيانات الحقيقية).
- شبكة عصبية التفاضلية اندماجية ثنائية الفرع (dual-branch fusion CNN) تجمع بين قناتي التيار والاهتزاز.
- صرامة هندسية برمجية غير معتادة في مشروع طلابي: 38 اختبار وحدة، وتكامل مستمر، وإبلاغ أمين عن النتائج بمقاييس ملائمة.

2. المحركات المتزامنة ذات المغناطيس الدائم (PMSM) وأعطائها

2.1 مبدأ العمل

المحرك المتزامن ذو المغناطيس الدائم هو آلة تيار متناوب ثلاثية الطور يحمل فيها العضو الدوار (الروتور) مغناطيس دائمة ويحمل العضو الثابت (الستاتور) ملفاً ثلاثي الطور. وعندما تُغذى ملفات العضو الثابت بتيار ثلاثي الطور متوازن، فإنها تُنشئ مجالاً مغناطيسياً دواراً؛ فتتقفل مغناطيس العضو الدوار على هذا المجال وتدور متزامنةً معه. وعلى خلاف المحرك الحثي، لا يوجد انزلاق (slip) ولا تيار في العضو الدوار، وهذا ما يمنح المحرك المتزامن ذا المغناطيس الدائم كفاءته العالية وكثافة عزمه المرتفعة.

ويُساوي ميزان الطاقة الأساسي للآلة بين القدرتين الكهربائية والميكانيكية، $v.i \sim T.\omega$: حيث يرتبط الجهد بالسرعة (ω) والتيار بالعزم (T). ولهذا يُعدّ التيار الكمية الطبيعية المتحكّم بها لضبط العزم، ولهذا أيضاً تحمل أشكال موجات التيار معلومات غنية عن الحالة الكهروميكانيكية للآلة.

وتُقاد المحركات المتزامنة ذات المغناطيس الدائم على الدوام تقريباً بخطط التحكم الموجّه حقلياً (Field-Oriented Control، FOC). ويستخدم التحكم الموجّه حقلياً موضع العضو الدوار (من مُرمز encoder أو مُقدّر لاحتسابي sensorless) لتحويل التيارات الطورية الثلاثة إلى مركبتين متعامدتين: تيار المحور المباشر (direct-axis) i_d (المحاذاة لتدفق العضو الدوار، ويبقى

مثالاً قرب الصفر) وتيار محور التربيع (**quadrature-axis**) i_q (المتعامد مع التدفق، وهو المنتج للعزم). ويضبط متحكمان تناسبيان-تكامليان (PI) كلا من i_d و i_q ، ويُولد طلبا للجهد الناتجان بواسطة عاكس (inverter) ذي تعديل عرض النبضة (PWM) (ثلاثة أنصاف جسور، مع حساس تيار على كل طور). والتحكم الموجه حقلياً مهم لهذا المشروع لسببين: فهو السياق الذي تُنتج فيه إشارات تيار المحرك المتزامن الحقيقية، وهو يشكل تلك الإشارات (إذ يتخذ المتحكم بفعالية بعض بصمات الأعطال، وهذا أحد أسباب أن الأعطال قد تكون أيسر رؤية في الاهتزاز منها في التيار).

2.2 BLDC مقابل PMSM

يرتبط المحرك المتزامن ذو المغناطيس الدائم ارتباطاً وثيقاً بالمحرك المستمر عديم الفرش (Brushless DC)، (BLDC والفرق العملي بينهما هو شكل القوة الدافعة الكهربائية الخلفية (back-EMF) وتيار القيادة: فمحرك BLDC ذو قوة دافعة خلفية شبه منحرفة (**trapezoidal**) ويقاد بتيارات شبه مربعة (شبه منحرفة)، بينما المحرك المتزامن ذو المغناطيس الدائم ذو قوة دافعة خلفية جيئية (**sinusoidal**) ويقاد بتيارات جيئية (عبر PWM جيئي). والطبيعة الجيئية لتيارات المحرك المتزامن تجعل التحليل في المجال الترددي والتحليل الزمني-الترددي ذا معنى خاص.

2.3 أنواع الأعطال الشائعة

عادةً ما تُصنّف أعطال الآلات الكهربائية إلى كهربائية وميكانيكية ومغناطيسية:

- **القصر بين لفات العضو الثابت (Inter-turn short stator circuit، ITSC)**: إن انهيار العزل بين لفات متجاورة من ملف الطور نفسه ينشئ حلقة مقصورة. ويدور تيار عطل كبير في اللفات المقصورة، مُنتجاً تسخيناً موضعياً يجعل انهيار العزل أكثر فأكثر. والقصر بين اللفات هو أكثر أعطال العضو الثابت شيوعاً، وهو العطل الأساسي المدروس في هذا المشروع. وهو يدخل لامتاثلات (asymmetries) مميزة ومرجّات توافقية/جانبية (side-band) إضافية في التيار، وبصمة اهتزازية متميزة.
- **إزالة المغنطة (Demagnetization)**: يؤدي الفقد الجزئي لقوة مغناط العضو الدوّار (بسبب فرط التسخين، أو التقادم، أو تيارات إزالة المغنطة الكبيرة) إلى خفض القوة الدافعة الخلفية وثابت العزم، ويدخل مرجّات دون-توافقية (sub-harmonic) ومرجّات جانبية حول التردد الأساسي. وفي هذا المشروع، تُمثل إزالة المغنطة بواسطة المولد الاصطناعي فقط، لغيابها عن مجموعة البيانات الحقيقية العامة.
- **الحمل الزائد / الإجهاد الحراري (Overload) / thermal stress**: يؤدي التشغيل المستمر فوق الحمل الاسمي إلى رفع التيار الأساسي وتغيير المحتوى التوافقي؛ وهو حالة تشغيل متدهورة أكثر منه عطلاً صريحاً، ويمثل هنا كذلك اصطناعياً.
- **الأعطال الميكانيكية** (تآكل المحامل، اللامركزية، eccentricity عدم المحاذاة) تقع خارج نطاق هذا المشروع، لكنها تُعالج طبيعياً بمنهجية المخطط الطيفي + الشبكة العصبية الالتفافية نفسها، ولا سيما على قناة الاهتزاز.

2.4 لماذا التيار والاهتزاز

نُستخدم طريقتا استشعار متكاملتان:

- تيار العضو الثابت يكاد يكون مجانياً في القياس - إذ توجد حساسات التيار أصلاً في كل نظام قيادة بالتحكم الموجّه حقلياً - ما يجعل التشخيص القائم على التيار جذاباً جداً صناعياً. لكنّ المتحكم ذا الحلقة المغلقة يكبت جزئياً بصمات الأعطال، وقد تكون بصمات العطل بين اللّفات ضعيفة في التيار عند مستويات الشدّة المنخفضة.
- الاهتزاز يتطلّب مقياس تسارع (accelerometer) لكنه يستجيب مباشرةً للآتوماتلات الكهرومغناطيسية والميكانيكية التي ينتجها العطل، ما يمنح غالباً بصمة عطل أقوى وأبقى بكثير. وتؤكد نتائجنا ذلك.

3. خلفية في معالجة الإشارات

إشارة الحرك $x(t)$ هي سلسلة زمنية أحادية البعد مأخوذة العينات بمعدل f_s . وأبسط وصف لها هو في المجال الزمني (time domain) (السعة مقابل الزمن)، الذي يظهر متى تحدث الأشياء لكنه لا يظهر أيّ ترددات موجودة. والأداة الكلاسيكية لهذا الأخير هي تحويل فورييه (Fourier Transform)، الذي يفكّك الإشارة إلى مجموع موجات جيّبة ويبلغ عن سعة كل تردد.

غير أنّ تحويل فورييه أعمى عن الزمن: فهو يخبرنا بأيّ الترددات موجودة على امتداد التسجيل بأكمله، لكنه لا يخبرنا متى تحدث. وبالنسبة لإشارة مستقرة (stationary) (إحصاءاتها ثابتة في الزمن) يكون هذا كافياً. أما إشارات أعطال المحركات فكثيراً ما تكون غير مستقرة (non-stationary) - عابرة أو معتمدة على الحمل أو معدّلة - ولهذا يكون تحويل فورييه غير كافٍ.

وهذا القيد جوهري، وليس عملياً فحسب. فمبدأ عدم اليقين (uncertainty principle) في معالجة الإشارات ينصّ على أنّ جداء الدقة الزمنية بالدقة الترددية محدود من الأسفل: $\Delta f \cdot \Delta t \geq \text{constant}$. فلا يمكننا أن نعرف كلاً من الزمن الدقيق والتردد الدقيق لحدث ما بدقة اعتباطية. ومن ثمّ يجب على أيّ طريقة زمنية-ترددية أن تجري مفاضلة، وتجربها الطرائق المختلفة بأساليب مختلفة. فتحويل فورييه قصير الزمن (Short-Time Fourier Transform، STFT) يثبت طول نافذة واحداً ومن ثمّ مفاضلة واحدة مستقلة عن التردد. أما تحويل المويجات (Wavelet Transform) فيجري مفاضلة أذكى معتمدة على التردد، وهو الطريقة المستخدمة في هذا المشروع.

4. تحويل الموجات والمخططات الطيفية

4.1 من الجيوب إلى الموجات

يربط تحويل فورييه الإشارة بموجات جيبيّة لانهائية الطول. أما المويجة (wavelet) ("الموجة الصغيرة") فهي بدلاً من ذلك تذبذب قصير العمر مُوضَّع في الزمن (time) in (localised). واستبدال الجيب الأبدى بمويجة مُوضَّعة كدالة تحليل هو الفكرة المحورية لتحويل الموجات: فلأن دالة التحليل نفسها ذات امتداد منتهٍ في الزمن، يمكن للنتيجة أن نخبرنا أين في الزمن يحدث كل مركّب ترددي.

تأهّل الدالة $\psi(t)$ لتكون مويجة (أمّا) إذا حققت شرطين:

1. متوسط صفري (المقبولية): (admissibility) تكاملها على كامل الزمن صفر ($\int_{-\infty}^{\infty} \psi(t) dt = 0$). أو بصورة مكافئة،

لا تملك المويجة مركّب تردد صفري / مركّب تيار مستمر (DC).

2. طاقة منتهية: $\int_{-\infty}^{\infty} |\psi(t)|^2 dt < \infty$ ، أي إنّ المويجة مُوضَّعة وتلاشى، على خلاف الجيب الذي يستمر إلى الأبد.

توجد عائلات موجات عديدة - Haar، Daubechies، Cofilet، Symlet، و Meyer، وقبعة المكسيكي (Mexican hat)، Gaussian، و Shannon، و Morlet. ومويجة Morlet هي الخيار المعياري للتحليل الزمني-الترددي للإشارات التذبذبية وهي المستخدمة هنا. وبتعبير بسيط، مويجة Morlet (الحقيقية) هي جيب تمام مضروب بجرس Gaussian، $\psi(t) = \exp(-t^2/2) \cdot \cos(\omega_0 t)$ - تذبذب "مُحمَّد" بحيث يتركز حول $t = 0$. وعملياً تُستخدم مويجة Morlet مركّبة (com-plex) $\psi(t) = \exp(-t^2/2) \cdot \exp(i\omega_0 t)$ ، يعطي مقدارها (magnitude) قياساً سلساً للطاقة المحلية عند تردد معطى (متجنباً تقاطعات الصفر التي قد تنتجها مويجة حقيقية بحتة). وفي هذا المشروع نستخدم مويجة Morlet المركّبة من Py- Wavelets 1.0-1.5 cmor (عرض النطاق 1.5، التردد المركزي 1.0)؛ ويستخدم مسار MATLAB مويجة Morlet التحليلية amor.

4.2 تحويل الموجات المستمر

يولّد تحويل الموجات المستمر (CWT) عائلة من الموجات "البنات" من المويجة الأم عبر عمليتين:

- الإزاحة (Translation) (مقبض زمني b): تنزلق المويجة على المحور الزمني، $\psi(t-b)$ ، مُحدّدة أين ننظر.
- القياس (Scaling) (مقبض ترددي a): تُمدّد المويجة أو تُضغَط، $\psi(t/a)$. فالمويجة المضغوطة (a صغير) تذبذب بسرعة وتطابق الترددات العالية؛ والمويجة الممدّدة (a كبير) تطابق الترددات المنخفضة.

ويعطي الجمع بين العمليتين المويجة البنت $\psi_{a,b}(t)$ - ويحصل على معامل تحويل الموجات المستمر $T(a,b)$ بربط الإشارة بهذه المويجة البنت - رياضياً تكامل لجداء الإشارة بالمويجة (المُرافقة، conjugated). وهذا تماماً جداء قياسي (dot product) يقيس التشابه: إذ يُحدّد $T(a,b)$ كمياً مدى قوة شبه الإشارة بموجة ذات القياس (التردد) المعطى عند

الزمن المعطى. ويُعدّ اجتياح b عند ثبات a تلافيفاً (convolution)؛ وينتج اجتياح كل أزواج (a, b) خريطة كاملة ثنائية البعد. وحيث يُسقط تحويل فورييه بُعداً واحداً (الزمن) على بُعد واحد (التردد)، يُسقط تحويل المويجات بُعداً واحداً على تمثيل ثنائي البعد زمني-ترددى.

4.3 المخطط الطيفي


المخطط الطيفي (scalogram) هو التمثيل المرئي لـ $|T(a, l)|$ - مقدار معاملات تحويل المويجات المستمر - على هيئة صورة ملوّنة، بالزمن على المحور الأفقي، والقياس (التردد) على المحور العمودي، واللون يرمّز طاقة (energy) كل تردد عند كل لحظة. وتشير المناطق الساطعة إلى طاقة تذبذبية قوية موضّعة؛ ويرمّز موضعها وشكلها البنية الزمنية-الترددية للإشارة، وهو بالضبط ما يحمل معلومات العطل.

ويعكس المخطط الطيفي بصورة مرئية مبدأ عدم اليقين: فعند الترددات المنخفضة يكون التحليل دقة ترددية جيدة لكن دقة زمنية رديئة (سمات عريضة ممطوطة أفقياً)، بينما عند الترددات العالية تكون له دقة زمنية جيدة لكن دقة ترددية رديئة (حادّ في الزمن، مشوّش في التردد). وهذه هي "صناديق هايزنبرغ (Heisenberg boxes)" للتمثيل. والأهم أنّ هذه الدقة المعتمدة على التردد متوافقة جيداً مع الإشارات الفيزيائية، حيث تكون الظواهر البطيئة عادةً مستمرة والظواهر السريعة عادةً عابرة.

4.4 لماذا المخططات الطيفية للشبكات العصبية الالتفافية

بتحويل كل نافذة إشارة إلى صورة مخطط طيفي، نحوّل مشكلة تشخيص الأعطال إلى مشكلة تصنيف صور (image classification). وهذا قوي لأنّ (i) بصمات الأعطال تصبح أنماطاً مكانية (نطاقات، نطاقات جانبية، نسيج) تصمد أمام تغييرات معتدلة في نقطة التشغيل، و(ii) يتيح لنا تسخير الآلية الكاملة للرؤية الحاسوبية الحديثة - الشبكات الالتفافية - لمهمة معالجة إشارات.

يُظهر الشكل 4.1 مخططات طيفية حقيقية من مجموعة بيانات KAIST لكلتا القناتين وكلتا الفئتين. ولاحظ كيف يُثري العطل بين اللغات النسيج الزمني-الترددى، ولا سيما في قناة الاهتزاز.



الشكل 4.1 - مخططات طيفية حقيقية من KAIST التيار والاهتزاز، السليم مقابل العطل بين اللغات.

الشكل 4.1 - مخططات طيفية حقيقية من KAIST (التيار والاهتزاز، السليم مقابل العطل بين اللغات). تهيمن على قناة التيار حزمة التردد الأساسي، بينما يظهر الاهتزاز بنية أغنى بكثير يمكن للشبكة العصبية الالتفافية استثمارها.

5. الشبكات العصبية الالتفافية

5.1 ما هي الشبكة العصبية الالتفافية

الشبكة العصبية الالتفافية (CNN) هي بنية تعلم عميق متخصصة في البيانات ذات البنية الشبكية مثل الصور. فالصورة بالنسبة للحاسوب هي شبكة من الأعداد (شدات البكسلات)؛ وتعالج الشبكة العصبية الالتفافية تلك الشبكة عبر سلسلة من الطبقات التي نتعلم آلياً اكتشاف الأنماط المكانية - من الحواف والنسج البسيطة في الطبقات المبكرة إلى البنى المعقدة الخاصة بالفئات في الطبقات المتأخرة. والشبكات العصبية الالتفافية مستوحاة على نحو فضفاض من تنظيم القشرة البصرية البيولوجية.

5.2 الطبقات

تمرر شبكة عصبية التفافية نموذجية صورة الدخل عبر المراحل التالية:

1. الطبقة الالتفافية (Convolutional layer). تنزلق مصفوفات صغيرة قابلة للتعلم ("مرشحات" filters أو "نوى kernels" عبر الصورة؛ وعند كل موضع يضرب المرشح بالبكسلات الكامنة ويجمع، منتجاً خريطة سمات (feature map) تبرز أين يحدث نمط معين (حافة، نطاق، نسج). وتنتج مرشحات كثيرة لكل طبقة خرائط سمات كثيرة.
2. التنفيع (ReLU). تُحوّل وحدة التصحيح الخطي (Rectified Linear Unit) القيم السالبة إلى صفر، مُدخلةً اللاحقة التي تتيح للشبكة نمذجة الأنماط المعقدة.
3. طبقة التجميع (Pooling layer). يُخفّض التجميع الأقصى (max-pooling) عينات كل خريطة سمات بإبقاء القيمة العظمى فقط في كل منطقة صغيرة، مُقللاً الحجم المكاني والحساب مع الحفاظ على أقوى الاستجابات وإضافة قدر من ثبات الانزياح (translation invariance).
4. التسطيح / التجميع الشامل (Flattening / global pooling). بعد عدة كَلّ التفاف-تجميع، تُختزل خرائط السمات ثنائية البعد إلى شعاع أحادي البعد - إما بالتسطيح (ربط جميع القيم) أو بالتجميع المتوسط الشامل (global average pooling) (متوسطة كل خريطة سمات إلى عدد واحد، وهو أخفّ وأكثر متانة تجاه فرط التخصيص).
5. الطبقة المتصلة بالكامل (الكثيفة، dense). تجري طبقة شبكة عصبية تقليدية الاستدلال النهائي على شعاع السمات وتُخرج درجات الفئات، مُسوأةً بدالة softmax إلى احتمالات الفئات.

5.3 لماذا الشبكات العصبية الالتفافية (وكُلفها)

تحلّ الشبكات العصبية الالتفافية مشكلتين عجزت عنهما الشبكات المتصلة بالكامل الأقدم في معالجة الصور. أولاً، مشاركة المعاملات (parameter sharing) - إذ يُعاد استخدام المرشّح نفسه عبر الصورة بأكملها - تُبقي عدد المعاملات قابلاً للإدارة، حيث تحتاج الشبكة المتصلة بالكامل إلى وزن منفصل لكل زوج بكسل-عصبون. ثانياً، يحفظ التلايف العلاقات المكانية (spatial relationships) بين البكسلات المتجاورة، وهي علاقات يُتلفها التسطيح في صف واحد. وأبرز كُلفها أنّ الشبكات العصبية الالتفافية نهمة للبيانات والحساب، وقد تعجز عن التعميم على تحويلات لم تُدرّب أو تُعزّز عليها، وهي معتمدة نسبياً ("صندوق أسود"). وفي هذا المشروع نخفّف كلفة البيانات بتعزيز البيانات (data augmentation)، وموازنة الفئات، وبنية صغيرة عن قصد، ونحن صريحون بشأن حدود التعميم التي تفرضها مجموعة البيانات.

6. إعداد البيانات

يُعدّ إعداد البيانات قلب هذا المشروع، والمرحلة ذات أكثر القرارات التصميمية. وكل معامل مذكور أدناه يقيم في ملف config.yaml واحد، وكل مقطع منتج مسجّل في ملف data/manifest.csv واحد يربط الإشارة -> المخطط الطيفي -> التسمية -> التقسيم. وهذا المانيفست هو المصدر الوحيد للحقيقة لجميع المراحل اللاحقة.

6.1 مصادر الإشارة

تُغذّي ثلاثة مصادر إشارة قابلة للتبديل خط المعالجة نفسه:

الدور	الأدوات	القنوات	المصدر
أساسي، النتائج المُبلّغ عنها	مُجَمِّل Python	التيار + الاهتزاز	مجموعة بيانات KAIST الحقيقية
التحقق البرمجي، المصدر الوحيد لفئتي إزالة المغنطة/الحمل الزائد	Python (simulate.py)	التيار	المولّد الاصطناعي
إشارات اختيارية قائمة على الفيزياء	شيفرات FOC + Simscape	التيار	محاكاة MATLAB

مجموعة البيانات الحقيقية الأساسية - KAIST. نستخدم مجموعة بيانات اهتزاز وتيار المحرك المتزامن ذي المغناطيس الدائم ثلاثي الطور ذي أعطال العضو الثابت (Mendeley) rgn5brrgrn، DOI رقم 10.17632/rgn5brrgrn.5، الترخيص CC-

(BY-4.0) وتحتوي على تيار العضو الثابت المأخوذ عيناته بمعدل 100 kHz والاهتزاز بمعدل 25.6 kHz، مسجلين على محركات بقدرة 1.0 / 1.5 / 3.0 kW، في ظل الحالات العادية (normal) وبين اللّفات (inter-turn) وبين الملفات (inter-coil) عبر عدة مستويات شدة عطل، مخزنة كلفات TDMS. وتجعل معدلات أخذ العينات المرتفعة منها مناسبة تماماً للتحليل الزمني-التردد. والعطلان بين اللّفات وبين الملفات كلاهما عطلا قِصر في ملف العضو الثابت وربطان بفئة واحدة InterTurn؛ أما التسجيلات ذات الشدة 0% فهي فئة Healthy.

مجموعة البيانات الثانوية - Zenodo (مرجعية فقط). مجموعة البيانات الشاملة لكشف وتشخيص الأعطال في أنظمة المحرك المتزامن ذي المغناطيس الدائم المقدّاة بعاكس (Zenodo 13974503) جرى تدقيقها لكنها لم تُستخدم للمخططات الطيفية: فهي بيانات حسّاسات جدولية مأخوذة عيناتها بمعدل 10 Hz فقط (Nyquist) عند 5 Hz، ولا تحمل محتوى زمنياً-ترددياً مفيداً لتحويل المويجات المستمر. وقد احتفظ بها كمرجع لمناقشة جودة البيانات مقابل ملائمة الطريقة.

المولّد الاصطناعي. يبني مولّد قابل لإعادة الإنتاج (python/simulate.py) إشارات تيار لجميع الفئات الأربع ببصمات MCSA مدفوعة فيزيائياً (التردد الأساسي والتوافقيات الفردية للسليم؛ توافقيات ثالثة/خامسة مرتفعة ونطاق جانبي للعطل بين اللّفات؛ مركّب دون-توافقي ونطاقات جانبية $k.f_r \pm f_0$ لإزالة المغنطة؛ تردد أساسي مرتفع وتوافقيات زوجية وضجيج للحمل الزائد). وهو يوفر تحقّقاً فورياً من بداية خط المعالجة إلى نهايته، والأمثلة الوحيدة لفنّي إزالة المغنطة والحمل الزائد.

6.2 الفئات

تعرّف أربع فئات في الضبط: Healthy (سليم)، و InterTurn (بين اللّفات)، و Demagnetization (إزالة المغنطة)، و Overload (الحمل الزائد). وتغطّي بيانات KAIST الحقيقية الفئتين الأوليين؛ بينما تظهر إزالة المغنطة والحمل الزائد في البيانات الاصطناعية فقط. ومن ثمّ فإنّ النتائج المُبلّغ عنها للبيانات الحقيقية هي مشكلة ثنائية الفئة (two-class) بين Healthy و InterTurn، مع الإبقاء على ضبط الفئات الأربع للتجارب الاصطناعية وللتوافق المستقبلي.

6.3 الاستيعاب والتقطيع

يقرأ كل تسجيل خام، ثم يُخفّض معدله (decimated) إلى معدل هدف موحّد قدره 10 kHz (تخفيض FIR مضاد للتشويه aliasing من 100 kHz للتيار ومن 25.6 kHz للاهتزاز). ويجعل التخفيض أحجام المخططات الطيفية قابلة للمعالجة مع الاحتفاظ بكل المحتوى الترددي ذي الصلة بالعطل (حتى 5 kHz). ثم يُقطّع كل تسجيل إلى نوافذ مدتها 0.5 ثانية بتراكب 50%؛ وتصبح كل نافذة عينة مُصنّفة واحدة. ولأنّ التسجيلات الخام طويلة (مئات الثواني)، فإنّ تسجيلاً واحداً يُنتج ما يزيد على ألف نافذة؛ وللإبقاء على توازن مجموعة البيانات من حيث التسجيلات وعلى عدد المخططات الطيفية قابلاً للمعالجة، يُحتفظ بـ 50 مقطعاً كحد أقصى لكل تسجيل، مأخوذة بخطوة (stride) متساوية لتغطّي التسجيل بأكمله بدلاً من ثوابه الافتتاحية فقط.

6.4 توليد المخططات الطيفية

يُحوّل كل مقطع إلى مخطط طيفي باستخدام PyWavelets: تُطبّق مويجة Morlet المركّبة 1.0-1.5 cmor على 128 قياساً متباعدة هندسياً بين 4 و256، ويُسوّى المقدار، ويُسقَط عبر خريطة الألوان jet، ويُحفظ كصورة PNG ملوّنة (RGB) بحجم 224 x 224 تحت `data/scalograms/<channel>/<class>`. ويلبّي تخطيط المجلدات المُسمّى بالفئات هذا المتطلب القائل بـ “حفظ الصور في مجلدات مصنّفة حسب الحالة”، وهو تماماً التخطيط الذي نتوقّه مصنّفات الصور. وقد أنتجت مجموعة البيانات الحقيقية بأكملها 3,150 مخططاً طيفياً (1,550 للتيار + 1,600 للاهتزاز). وينتج مسار MATLAB المكافئ (`matlab/scalogram/`) التخطيط نفسه باستخدام Toolbox. Wavelet

6.5 تقسيم تدريب / تحقّق / اختبار خالٍ من التسرّب

إنّ التقسيم العشوائي الساذج لـ المقاطع سيضع نوافذ من التسجيل نفسه في مجموعتيّ التدريب والاختبار معاً. ولأنّ النوافذ المتجاورة من تسجيل واحد مترابطة بشدّة، فإنّ هذا التسرّب البياني (data leakage) سيُضخّم درجة الاختبار ويعطي نتيجة متفائلة زوراً. ولهذا نقسّم حسب التسجيل: تُسند جميع مقاطع التسجيل إلى التقسيم نفسه (70% تدريب / 15% تحقّق / 15% اختبار)، مطبّقة طبقياً (stratified) حسب الفئة، ويُجرى التقسيم مستقلاً لكل قناة بحيث تُمثّل كل قناة تمثيلاً سليماً. وقد استلزم الأمر تحسيناً دقيقاً لكن مهماً: فع وجود أربعة تسجيلات سليمة فقط، أرسل التقريب العادي جميعها إلى مجموعة التدريب، تاركاً التحقّق والاختبار بلا أمثلة سليمة. ولهذا عدّل إجراء التقسيم ليضمن تسجيلاً واحداً على الأقل لكل تقسيم لأيّ فئة لديها عدد كافٍ من التسجيلات، بحيث تصبح كل فئة قابلة للتقييم. وهذا السلوك مشمول باختبارات الوحدة.

6.6 عدم توازن الفئات والموازنة

مجموعة البيانات الحقيقية شديدة عدم التوازن: لا يوجد سوى 4 تسجيلات سليمة مميّزة مقابل نحو 60 تسجيل عطل. وإذا دُرِبَت الشبكة العصبية الالتفافية بسدّاجة على هذا التوزيع، فإنها تتعلّم التنبؤ بـ “InterTurn” لكل شيء وتحقّق دقة خام مرتفعة خادعة قدرها 80% بينما لا تكشف محرّكاً سليماً قطّ (استدعاء السليم 0.00). ولمنع هذا الانهيار، نقلل أخذ عينات الفئة الأكثرية majority the (undersample) class في مجموعتيّ التدريب والتحقّق فقط، بحيث يتلقّى النموذج إشارة تعلّم متوازنة؛ أما مجموعة الاختبار فتترك عمداً على توزيعها الطبيعي بحيث تعكس المقاييس المبلّغ عنها الواقع. ولأنّ الدقة الخام مضلّلة على مجموعة اختبار غير متوازنة، نبلّغ عن الدقة المتوازنة (balanced accuracy) (متوسط استدعاءات الفئات) وmacro-F1 ثنائي الفئة كمقاييس رئيسية. ويُطبّق تعزيز البيانات (انعكاسات أفقية عشوائية) على صور التدريب، كما يتوفّر أيضاً ترجيح الفئات بالتردد العكسي (inverse-frequency weighting). class

7. نموذج الشبكة العصبية الالتفافية والتدريب

7.1 البنية المرجعية (Baseline)

المصنّف أحادي القناة هو شبكة عصبية التفافية مُدمجة:

224x224x3 Input

MaxPool2x2 >- ReLU >- 3x3), Conv2D(32 >-

MaxPool2x2 >- ReLU >- 3x3), Conv2D(64 >-

MaxPool2x2 >- ReLU >- 3x3), Conv2D(128 >-

Dropout(0.5) >- Flatten >-

ReLU >- Dense(128) >-

Softmax >- Dense(num_classes) >-

تستخرج ثلاث كُتل التفاف-تجميع (32 و 64 و 128 مرثّحاتاً) هرميةً من السمات؛ ويكافئ إسقاط (dropout) بنسبة 50% قبل الطبقة الكثيفة فرط التخصيص؛ ويُنتج خرج softmax احتمالات الفئات. والبنية صغيرة عن قصد، ملائمة لمجموعة بيانات من بضعة آلاف صورة.

7.2 بنية الاندماج

لاستثمار القناتين في آنٍ واحد، يشغل نموذج الاندماج ثنائي الفرع (dual-branch fusion) (build_fusion_cnn) فرعين التفافيين مستقلين - أحدهما لمخطط التيار الطيفي والآخر لمخطط الاهتزاز الطيفي - ينتهي كلُّ منهما بالتجميع المتوسط الشامل (global average pooling)، ثم يربط شعاعي السمات ويصنّف الناتج عبر رأس كثيف مشترك. ويُستخدم التجميع المتوسط الشامل (بدلاً من التسطيح) في فرعي الاندماج لأنّ تسطيح خرائط سمات 128 x 26 x 26 لفرعين يُنتج طبقة كثيفة هائلة تستنزف الذاكرة؛ فيما يُعدّ التجميع المتوسط الشامل الخيار المعياري الأخفّ بكثير ويضيف تنظيمًا (regularisation).

7.3 إعداد التدريب

تُدرّب جميع النماذج بمُحسّن Adam ودالة خسارة الإنتروبيا المتقاطعة القوية المتفرقة (sparse cross- categorical entropy). ويمنع الإيقاف المبكر (Early stopping) (الصبر 5، مع استعادة أفضل الأوزان) فرط التخصيص ويتجنّب هدر الحساب. ويستخدم التدريب حجم دفعة 32 (و 16 لنموذج الاندماج الأثقل) حتى 30 حقبة (epochs) وتُضمن قابلية إعادة الإنتاج ببذرة عشوائية ثابتة (42) في كامل مراحل الاستيعاب والتقسيم والموازنة والخلط. وتُستخدم TensorFlow 2.16 / Keras ويُنفذ التشغيل بأكمله على المعالج المركزي (CPU).

7.4 الإقران للاندماج

يحتاج نموذج الاندماج إلى مخططات طيفية مقترنة للتيار والاهتزاز. وتخزن مجموعة بيانات KAIST الطريقتين كـتسجيلين منفصلين لحالة التشغيل نفسها؛ ولأن كليهما مخفض إلى المعدل نفسه ومقطع تقطيعاً متطابقاً، فإن المقطع k من تسجيل التيار والمقطع k من تسجيل الاهتزاز يغطيان الجزء نفسه من التشغيل - وهو إقران زمني تقريبي. ولتجنب التسرب في المشكلة المندمجة، يُسند تقسيم التدريب/التحقق/الاختبار للاندماج على مستوى الحالة (condition) (level)، بحيث تقع طريقتا الحالة دائماً في التقسيم نفسه.



8. النتائج والتحليل

جميع النتائج أدناه على بيانات KAIST الحقيقية، وعلى تسجيلات مُحتجزة (held-out)، ولمشكلة Healthy مقابل Inter-Turn، مع تدريب متوازن ومجموعة اختبار طبيعية.

8.1 نتائج القناة الواحدة والاندماج

استدعاء العطل بين اللّفات	استدعاء السليم	Macro-F1	الدقة المتوازنة	دقة الاختبار	القناة
1.00	1.00	1.00	1.00	1.00	الاهتزاز
0.75	1.00	0.76	0.88	0.80	الاندماج (التيار+الاهتزاز)
0.37	1.00	0.49	0.69	0.50	التيار

Real KAIST PMSM — Healthy vs Inter-turn (held-out recordings)



الشكل 8.1 - مصفوفتا الالتباس لثنائي التيار والاهتزاز.

الشكل 8.1 - مصفوفتا الالتباس (*confusion matrices*) لمجموعة الاختبار (تسجيلات مُحْتَجَزَة). يسار: التيار - جميع الأعطال مقروءة خطأً أو مُقسَّمة. يمين: الاهتزاز - فصل مثالي. ويظهر كل عنوان الدقة المتوازنة و *macro-F1*. تظهر أمثلة المخططات الطيفية الحقيقية في الشكل 4.1؛ والمقاييس القابلة للقراءة آلياً في `results/real_metrics.json` و `results/report_{current,vibration,fusion}.json`.

8.2 المناقشة

الاهتزاز هو القناة القوية. تصنّف الشبكة العصبية الالتفافية للاهتزاز كل مقطع اختبار مُحْتَجَز تصنيفاً صحيحاً (الدقة المتوازنة 1.00). وهذا متسق مع الفيزياء: فالقصر بين اللّفات يُنتج لامتثالاً كهروميكانيكياً بارزاً يتجلى بقوة في الاهتزاز، وقناة الاهتزاز ليست عُرضةً للفعل الكابت لمُتَحَكِّمات تيار التحكم الموجّه حقيقياً. وتُظهر أمثلة المخططات الطيفية ذلك مرئياً - إذ يكون مخطط الاهتزاز الطيفي للعطل بين اللّفات أغنى ملحوظاً في النسيج الزمني-الترددى من المخطط السليم.

التيار هو القناة الضعيفة. لا تبلغ الشبكة العصبية الالتفافية للتيار سوى دقة متوازنة قدرها 0.69. وبعد الموازنة تكشف كل حالة سليمة (استدعاء السليم 1.00) لكنها تفوّت نحو 63% من الأعطال (استدعاء العطل بين اللّفات 0.37). وبعبارة أخرى، فإنّ بصمة العطل بين اللّفات في تيار العضو الثابت ضعيفة عند مستويات الشدّة الحاضرة، ويزيد المتحكم ذو الحلقة المغلقة في تخييدها. وهذه نتيجة سلبية أمينة ومنطقية فيزيائياً، وليست فشلاً في خط المعالجة (إذ يُنتج خط المعالجة نفسه 1.00 على الاهتزاز).

الاندماج يقع في المنتصف. يُحسّن النموذج ثنائي الفرع (دقة متوازنة 0.88) بقدر كبير على التيار وحده، لكنه لا يتفوّق على الاهتزاز وحده على هذه المجموعة من البيانات: فإضافة قناة ضعيفة إلى قناة قوية لم تساعد هنا، ويستخدم رأس الاندماج التجميع المتوسط الشامل بدلاً من رأس التسطيح في نماذج القناة الواحدة، ومن ثمّ تكون المقارنة إرشادية لا مضبوطة بدقة. ومع مشكلة أصعب (فئات أكثر، شدّات أدنى) يُتوقّع أن يُظهر الاندماج قيمته.

8.3 أهمية المقياس الصحيح

النقطة التحليلية الأهم في هذا المشروع هي أنّ الدقة الخام هي المقياس الخاطئ هنا. فعلى مجموعة الاختبار الطبيعية (50 سليماً / 200 معطوباً)، يُحقّق نموذج يتنبأ بـ "معطوب" بصورة عمياء دقة 80% رغم كونه عديم الفائدة سريرياً (إذ لا يكشف محرّكاً سليماً قطّ). والإبلاغ بالدقة المتوازنة و *macro-F1* يكشف هذا فوراً، وهو ما أتاح لنا اكتشاف انهيار الفئة الأكثرية ثمّ إصلاحه. وهذا مُكَمِّم في القسم التالي.

8.4 القيد الرئيسي

تحتوي مجموعة البيانات العامة على أربعة تسجيلات سليمة مميزة فقط (مقسمة 2 تدريب / 1 تحقق / 1 اختبار). وإن درجة اهتزاز مثالية على تسجيل سليم واحد مُحْتَجَز لا يمكنها وحدها أن تستبعد إمكانية أن تكون الشبكة قد تعلّمت خصائص خاصة بذلك التسجيل (التركيب، الجلسة، الظروف المحيطة) بدلاً من مفهوم قابل للتعميم عن "السليم". ويتطلب تأكيد التعميم مزيداً من التسجيلات السليمة المستقلة - محركات وأحمالاً وجلسات قياس أكثر. وينبغي ذكر هذا القيد صراحةً في أي استخدام لهذه النتائج، وهو الهدف الأول لجمع البيانات المستقبلي.

9. تجارب التحسين

يُبلغ هذا القسم عن التجارب المنهجية التي تتطلبها المهمتان الفرعيتان 5 و 6 (أثر كمية/جودة البيانات، وتحسين النموذج). وقد أُنتجت جميع التشغيلات الستة عشر بواسطة `python/experiments.py` (كل تشغيل في عملياته الفرعية الخاصة، مع نقاط تفتيش checkpointing وقابلية للاستئناف) وقِيّمت على مجموعة الاختبار المُحتَجَزَة الطبيعية غير المتوازنة. والبيانات الكاملة في `results/experiments_real.json`؛ والمناقشة الموسّعة في `docs/experiments.md`.

9.1 أثر موازنة الفئات

استدعاء العطل					
بين اللّفات	استدعاء السليم	Macro-F1	الدقة المتوازنة	الموازنة	القناة
1.000	0.600	0.851	0.800	off	current
0.385	1.000	0.502	0.693	on	current
1.000	1.000	1.000	1.000	off	vibration
1.000	1.000	1.000	1.000	on	vibration

من دون موازنة، يخاز نموذج التيار إلى الفئة الأكثرية - إذ يفوّت 40% من المحركات السليمة هنا وينهار إلى استدعاء سليم قدره 0% في التشغيلات المتكررة (الدقة الخام 0.80 = المعدل الأساسي base rate). وتُجبر الموازنة على كشف السليم (الاستدعاء -> 1.00)، كاشفةً قابلية الفصل الضعيفة الحقيقية لهذه القناة. أما الاهتزاز فلا يتأثر (مثالي أصلاً).


9.2 أثر حجم صورة المخطط الطيفي

القناة	96 px	160 px	224 px
current (الدقة المتوازنة)	0.682	0.730	0.760
vibration (الدقة المتوازنة)	1.000	1.000	1.000

بالنسبة لقناة التيار الضعيفة، ترتفع الدقة المتوازنة رتيباً (**monotonically**) مع الدقة (0.68 -> 0.76) - فبصمة العطل بين اللّفات تقيم في التفاصيل الزمنية-الترددية الدقيقة. أما الاهتزاز فُشِّعَ عند كل حجم، ومن ثمّ فإنّ صور اهتزاز بحجم 96 px ستُدرَّب وتُستدَلّ أسرع بنحو 5 أضعاف من دون أيّ خسارة في الدقة.

9.3 أثر حجم مجموعة التدريب (كمية البيانات)

القناة	%25 (n~50)	%50 (n~100)	%100 (n~200)
current (الدقة المتوازنة)	0.693	0.698	0.698
vibration (الدقة المتوازنة)	0.970	1.000	1.000




منحنى التعلّم

الشكل 9.1 - الدقة المتوازنة مقابل عدد صور التدريب. يبلغ الاهتزاز 0.97 بنحو 46 صورة فقط و1.00 بنحو 98؛ أما التيار فهو مسطّح عند نحو 0.70 بصرف النظر عن حجم البيانات. وهذا أوضح اكتشاف في الدراسة: فسقف قناة التيار محدّد ب جودة

الإشارة لا كميّتها - فزيد من بيانات التيار لن يساعد، في حين ينجح الاهتزاز بقدر قليل جداً. وهذا يجيب مباشرةً عن المهمة الفرعية 5: ففي هذه المشكلة، تهيمن جودة مجموعة البيانات (القناة، الشدّة) على كميّتها.

9.4 أثر عمق الشبكة (عدد الطبقات)

القناة	كَلّ 4	كَلّ 3	كَلّتان
current (الدقة المتوازنة)	0.69	0.70	0.71
vibration (الدقة المتوازنة)	1.00	1.00	1.00




حذف العمق

الشكل 9.2 - أثر عدد الكَلّ الالتفافية. العمق لا يكاد يغيّر النتيجة: يبقى التيار ~0.69-0.71 (قيد جودة الإشارة لا السّعة)، والاهتزاز مثالي عند كل عمق. ولاحظ أن تقليل الكَلّ يعني زيادة المعاملات (تجميع أقل -> خريطة مسطّحة أكبر): كَلّتان ~23.9M، 3 كَلّ ~11.2M، 4 كَلّ ~5.1M. ومن ثمّ 3 كَلّ هي الخيار الافتراضي - دقة قرب الأفضل بعدد معاملات معتدل وخطر فرط تخصيص أقل من شبكة أعمق.

9.5 أثر بنية النموذج (تحسين الشبكة)

ثلاث بنى، بيانات متوازنة، px: 224 **baseline** (شبكة من ثلاث كتل من الصفر)، **modern** (Conv-BatchNorm-ReLU + تجميع متوسط شامل + جدولة معدل التعلم)، و **transfer** (عمود MobileNetV2 مُدرَّب مسبقاً ومجمَّد + رأس صغير).

القناة	baseline	modern	transfer
current (الدقة المتوازنة)	0.70	0.50	0.89
vibration (الدقة المتوازنة)	1.00	0.59	1.00




حذف البنية

الشكل 9.3 - مقارنة البنى. التعلّم بالنقل (MobileNetV2) هو التحسين النظيف الفعّال: يرفع قناة التيار الضعيفة من 0.70 إلى **0.89** (استدعاء العطل بين اللّقات 0.40 -> 0.77) ويُبقي الاهتزاز عند 1.00 - نخصائص ImageNet المُدرّبة مسبقاً تنتقل جيداً إلى المخططات الطيفية رغم أنها ليست صورياً طبيعية. أما بنية **modern** من الصفر فانهارت على هذه المجموعة الصغيرة (يحتاج BatchNorm دفعات أكبر)، ما يؤكّد أنّ الخصائص المُدرّبة مسبقاً تتفوّق على التدريب الأعقد عند ندرة البيانات.

9.6 هل تساعد البيانات المُولّدة؟ (التدريب المسبق الاصطناعي والتعزيز)

اختبرنا ما إذا كان توليد البيانات يرفع قناة التيار الضعيفة، على مجموعة اختبار التيار الحقيقية المحجوزة:

الاستراتيجية	الموازنة الدقة	السليم استدعاء	العطل استدعاء
(baseline) الأساس	0.70	1.00	0.40
+ SpecAugment	0.71	1.00	0.42
حقيقي دقيق ضبط -> اصطناعي مسبق تدريب	0.35	0.00	0.71



استراتيجيات البيانات المولدة

الشكل 9.4 - استراتيجيات البيانات المولدة على قناة التيار الحقيقية. النتيجة سلبية وأمنية: التعزيز منح تحسناً مهماً، والتدريب المسبق على بيانات الاصطناعية الغنية أضرَّ (0.70 -> 0.35) - وهي فجوة مجال (domain gap)، لأنَّ الإشارة "السليمة" الاصطناعية نموذج مُبسَّط لا تستطيع المجموعة الحقيقية الصغيرة تصحيح إحصاءاته. ويتناقض هذا مع النقل من ImageNet (\$9.5، 0.89\$): فالخصائص الواقعية العامة تنتقل، أما المحاكى اليدوي الضيق فلا. الخلاصة: البيانات الاصطناعية قيِّمة للتحقق البرمجي ولقنَّتي إزالة المغنطة/الحمل الزائد، لكنها لا تُغني عن تنوُّع التسجيلات الحقيقية - وهو الرافعة الحقيقية (انظر \$8.4\$).

9.7 ضوابط فرط التخصيص

يتضافر الإسقاط (0.5)، والتجميع المتوسط الشامل في رأس الاندماج، وتعزيز التدريب (انعكاسات عشوائية)، والإيقاف المبكر (الصبر 5، مع استعادة أفضل الأوزان)، والبنية الصغيرة، في إبقاء النموذج بعيداً عن فرط التخصيص؛ ويؤكد منحني التيار المسطح ومنحني الاهتزاز المُشَبَّع أنَّ السَّعة (capacity) ليست القيد المُلْزِم - بل جودة الإشارة (التيار) وحدَّ التسجيلات

10. الاستنتاجات والعمل المستقبلي

10.1 الاستنتاجات

- بنينا خط معالجة متكاملًا وقابلًا لإعادة الإنتاج لتشخيص أعطال المحرك المتزامن ذي المغناطيس الدائم يحوّل إشارتي التيار والاهتزاز إلى مخططات طيفية بتحويل الموجات المستمر ويصنّفها بشبكة عصبية التلافية، مُحَقِّقًا المهمة المُسَنَدَة من بدايتها إلى نهايتها.
- على البيانات الحقيقية، تكشف المخططات الطيفية القائمة على الاهتزاز أعطال العضو الثابت بين اللّقات بدقة متوازنة قدرها 1.00 على تسجيلات مُحْتَجَزة، في حين تكون المخططات الطيفية القائمة على التيار أضعف ملحوظاً (0.69) - وهي نتيجة واضحة ومؤسّسة فيزيائياً بشأن اختيار القناة.
- كانت المعالجة الصحيحة لـ عدم توازن الفئات واستخدام الدقة المتوازنة / macro-F1 بدلاً من الدقة الخام أمرين ضروريين للحصول على نتائج جديرة بالثقة والإبلاغ عنها.
- العمل مدعوم بـ 38 اختبار وحدة وتكامل مستمر، ومتاح علناً ليمكن باحثون آخرون من إعادة إنتاجه وتوسيعه.

10.2 القيود

القيد الرئيسي هو العدد الصغير من التسجيلات السليمة المستقلة، الذي يقيّد مدى قوة ادعاء التعميم. وإزالة المغنطة والحمل الزائد حاضران اصطناعياً فقط. ومقارنة الاندماج إرشادية لا مضبوطة بدقة.

10.3 العمل المستقبلي

- اقتناء مزيد من التسجيلات المستقلة (محركات وأحمالاً وجلسات أكثر)، ولا سيما السليمة منها، للتحقق من التعميم.
- مجموعة بيانات متعددة القنوات مقترنة ومتزامنة لتمكين نموذج الاندماج من تحقيق إمكاناته.
- أهداف واعية بالشدة (severity-aware) (انحدار regression أو تصنيف رتبي ordinal لشدة العطل) بدلاً من الكشف الثنائي.
- القابلية للتفسير (Explainability) (مثل Grad-CAM) لتأكيد أنّ الشبكة تنتبه إلى مناطق ذات معنى فيزيائي من المخطط الطيفي، وهو ما يساعد أيضاً على استبعاد اختصار هوية التسجيل.
- النشر التشغيلي الفوري (On-line deployment) ضمن نظام قيادة بالتحكم الموجه حقيقياً للمراقبة في الزمن الحقيقي.

11. المراجع

1. Data, Mendeley Faults. *Stator with PMSM Three-Phase of Dataset Current and Vibration* KAIST. (CC-BY-4.0). 10.17632/rgn5brrgrn.5 DOI:
2. Zen- Systems. *PMSM Inverter-Driven in Diagnosis and Detection Fault for Dataset Comprehensive* (CC-BY-4.0). 13974503 record odo,
3. 2015, *IFAC-PapersOnLine* Modelling,” Fault Winding Stator PMSM “Interior al., et Otava L. 10.1016/j.fiacol.2015.07.055. DOI:
4. block “PMSM” and Faulted” - (PMSM) Motor Synchronous Magnet “Permanent MathWorks, <https://www.mathworks.com/help/sps/documentation>.
5. *network. neural ResNet using motor synchronous magnet permanent in classfication faults Electrical* .379692489 publication ResearchGate
6. *Dataset. Winding Stator Faults ITSC PMSM Three-phase* DataPort, IEEE <https://pywavelets.readthedocs.io/Transform.WaveletContinuous-documentationPyWavelets>.
7. <https://www.tensorflow.org/documentation>. Keras / TensorFlow
8. 9. ملاحظات دراسية ومصادر تعليمية إضافية مدرجة في references.md، والخلفية حول الشبكات العصبية الالتفافية مستمدة من أدبيات التعلّم العميق المعيارية (انظر notes.md).

يصف هذا التقرير البرمجيات والتجارب في مشروع *pmsm-fault-diagnosis-cnn-scalogram*. وجميع الأشكال المشار إليها موجودة في *results/*، وجميع المعاملات في *config.yaml*، وجميع النتائج قابلة لإعادة الإنتاج بالأوامر الموجودة في ملف *README.md* الخاص بالمشروع.

الملحق A - إعادة إنتاج النتائج

```
make setup          # create .venv (Python 3.10) + install deps
make test           # run the 38-test suite

# Real data (after downloading the KAIST dataset into data/raw/mendeley_pmsm/):
.venv/bin/python -m python.ingest_mendeley # read TDMS, decimate, segment
```

```

make scalograms          # render CWT scalograms (PyWavelets)
.venv/bin/python -m python.run_split    # leakage-free, per-channel split
make train SIGNAL=current EPOCHS=30 && make evaluate SIGNAL=current
make train SIGNAL=vibration EPOCHS=30 && make evaluate SIGNAL=vibration
make train-fusion EPOCHS=30          # dual-branch current+vibration
.venv/bin/python -m python.experiments    # ablation studies

# Synthetic end-to-end (no download needed):
make demo

```

الملحق B - الضبط الأساسي (config.yaml)

المعنى	القيمة	المعامل
مجموعة التسميات	InterTurn, Healthy, Overload Demagnetization,	classes
القنوات	vibration current,	signal_types
طول المقطع	0.5	window_seconds
تراكب النافذة الكسري	0.5	overlap
Hz بعد التخفيض	10000	target_fs
حدّ لتقييد عدد المخططات الطيفية	50	max_segments_per_recording
ضلع صورة PNG المربعة	224	image_size
موجة Morlet المركبة (مسار Python)	cmor1.5-1.0	wavelet_py
قياسات تحويل الموجات المستمر (4-256 (geomspace	128	n_scales
تقليل أخذ عينات الأكثرية في التدريب/التحقق	true	balance_train
بذرة مولّد الأعداد العشوائية العامة	42	seed

الملحق C - تخطيط المستودع

```
python/
  balance ,split ,scalogram ,(ingest modules pipeline
  experiments) ,train_fusion ,evaluate ,train ,model ,data_loader
  tests unit 38 python/tests/
  path) (alternative scripts -exportsignal + scalogram MATLAB matlab/
  (gitignored) manifest.csv ,>/<class>/<channelscalograms/ ,raw/ data/
  (gitignored) models .keras trained models/
  summary.md ,JSON metrics ,figures results/
  -audit.mddata ,experiments.md ,presentation/ ,report/ docs/
  CITATION.cff . targets Makefile . parameters all config.yaml
```

الملحق D - مخطط المانيست (data/manifest.csv)

- scalogram_path split, recording_id, dataset_name, fs, severity, class, signal_type, source, signal_id, صف واحد لكل مقطع، وهو المصدر الوحيد للحقيقة الذي يربط كل نافذة إشارة بمخططها الطيفي وتسميتها وتقسيمها.

الملحق E - جرد الاختبارات (38 اختباراً)

التحقق من الضبط، عمليات CRUD على المانيست، التقسيم الحالي من التسرب (بما في ذلك ضمانات الفئات الصغيرة)، التقطيع، تحليل أسماء ملفات KAIST موازنة الفئات، ترجيح الفئات، شكل المخطط الطيفي، المولد الاصطناعي، فهرسة محمل البيانات، بناء النموذج المرجعي ونموذج الاندماج، إقران الاندماج (لا حالة تمتد عبر التقسيمات)، اختبار دخان (smoke test) للتدريب، مقاييس التقييم (بما في ذلك مجموعة جزئية من الفئات). وتتخطى الاختبارات المعتمدة على TensorFlow تخطيطاً نظيفاً عند غياب TF.

الملحق F - تدقيق مجموعات البيانات

الحكم	f_s	الفئات	الإشارة	مجموعة البيانات
مختارة (أساسية)	25.6 / kHz 100	normal,	التيار + الاهتزاز	KAIST
	kHz	inter-turn,		rgn5brrgrn
		inter-coil		

الحكم	f_s	الفئات	الإشارة	مجموعة البيانات
مرجعية فقط (بطيئة جداً على تحويل الموجات المستمر)	Hz 10	inverter + normal faults	حساسات جدولية	Zenodo 13974503
غير مستخدمة (محبوبة بتسجيل دخول)	منخفض	-	تحكم/جدولي	pmsm- Kaggle smart-control
بديلة إن لم تتوفر KAIST	-	inter-turn	التيار	IEEE-DataPort ITSC PMSM

ملاحظة حول الطول/الصيغة: حرّر هذا التقرير بصيغة Markdown وعند تنزيده إلى Word A4/Letter أو LaTeX مع الأشكال والجداول وتباعداً أسطر 1.5-1.15 يمتدّ على 25-35 صفحة المطلوبة.