

تشخيص أعطال محركات PMSM باستخدام صور Scalogram Wavelet
والشبكات العصبية الالتفافية

استخدام الشبكات العصبية الالتفافية (CNN) لتحليل صور Scalogram Wavelet في تشخيص أعطال محركات PMSM

«اسم الجامعة - الكلية» . «القسم / الاختصاص»

إعداد الطالبين: ملهم فتنة . محمد زين قباني

إشراف: «د. اسم المشرف» . العام الدراسي: «2025-2026»

١. المشكلة

- ▶ محركات PMSM تشغل السيارات الكهربائية والروبوتات وأنظمة التحكم الصناعية ومُشغلات الطيران.
- ▶ أكثر أعطال العضو الثابت شيوعاً - القصر بين اللفات (inter-turn) - قد يتطور إلى انهيار كامل للملف خلال دقائق.
- ▶ الهدف: كشف الأعطال آلياً وباكراً من إشارات المحرك نفسه.
- ▶ الطرق التقليدية (تحليل طيف التيار) تتطلب خبيراً يعرف مسبقاً أي تردد يراقب، وتضعف عند تغيير السرعة والحمل.

٠٢. الفكرة

تحويل مشكلة الإشارة إلى مشكلة صورة.

الإشارة <- تقطيع <- CWT <- صورة Scalogram <- CNN <- تصنيف الحالة
(تيار/اهتزاز) (مويجة Morlet) (224x224) سليم / عطل بين اللفات

► الشبكة نتعلم بصمات العطل بنفسها - دون هندسة سمات يدوية.

► قناتان مدروستان: تيار العضو الثابت والاهتزاز.

٣. منظومة المعالجة


- المصادر: مجموعة بيانات KAIST الحقيقية (تيار + اهتزاز)، ومولّد إشارات اصطناعي، ومحاكاة (FOC MATLAB) + (Simscape).
- ملف إعدادات واحد + بيان (**manfiest**) واحد يربط: إشارة -> scalogram -> تصنيف -> تقسيم - قابل للتكرار بالكامل.
- مُنفَّذة بلغة Python، TensorFlow/Keras، (PyWavelets) دون الحاجة إلى MATLAB، مع ٣٨ اختبار وحدة + تكامل مستمر (CI).

٤. محرك PMSM وأعطاله

- ▶ PMSM: دوّار بمغناطيس دائم يتعقّب الحقل الدوّار للعضو الثابت -> يدور بشكل متزامن، بلا انزلاق -> كفاءة عالية.
- ▶ يُقاد عبر التحكم الموجّه حقلياً (FOC) - وحساسات التيار موجودة أصلاً في المُشغّل.
- ▶ الأعطال المدروسة:
- ▶ القصر بين اللفات (الأساسي، بيانات حقيقية)
- ▶ إزالة المغنطة، الحمل الزائد (اصطناعية)

المحرك ونظام التحكم

Speed PI
($\omega^* \rightarrow iq^*$)



PMSM مقابل نظائره

Commutation
Back-EMF
Efficiency
Torque density
Control complexity
Maintenance

كشف العطل - اليوم مقابل هذا العمل

Manual
(thermal c
insulation

٥. لماذا الموجات وليس فورييه؟


- ▶ تحويل فورييه أعمى زمنياً - لا يخبرنا متى يحدث التردد.
- ▶ إشارات الأعطال غير مستقرة (عابرة، تعتمد على الحمل).
- ▶ مبدأ عدم اليقين: $\Delta t \cdot \Delta f \geq \text{ثابت}$ - يستحيل دقة زمنية وترددية مثاليّتان معاً.
- ▶ الموجات = موجات قصيرة موضعية -> دقة ترددية متغيرة، مثالية للظواهر العابرة.

٦. تحويل الموجات المستمر (CWT) ومخطط الطيف

- ▶ نُقيّس موجية Morlet (مقبض التردد) ونُلقها (مقبض الزمن).
- ▶ كلّ معامل = تشابه الإشارة مع تلك الموجة عند ذلك الزمن.
- ▶ Scalogram = صورة ملوّنة للطاقة مقابل الزمن (س) والتردد (ص).
- ▶ الحُزْم والنطاقات الجانبية الساطعة = بصمات العطل التي تراها الشبكة.

٧. أمثلة على المخططات (بيانات KAIST الحقيقية)

current



٨. مجموعة البيانات

► مجموعة KAIST لأعطال العضو الثابت (Mendeley rgn5brrgrn، رخصة .CC-BY-4.0)

► التيار بمعدّل 100 kHz، الاهتزاز 25.6 kHz -> خُفّضاً إلى 10 kHz.

► 3,150 مقطع scalogram (نوافذ 0.5 ثانية، تداخل 50%).

القناة	سليم	اللفات بين عطل
تيار	200 4) تسجيلات (	1350 27) تسجيل (
اهتزاز	200 4) تسجيلات (	1400 28) تسجيل (

٩. تقسيم خالٍ من التسرب

► التقسيم حسب التسجيل لا حسب المقطع >- لا نوافذ مترابطة بين التدريب/الاختبار (لا تسرب بيانات).

► مُصنّف حسب الفئة، لكل قناة، بنسبة 15 / 15 / 70.

► انتباه خاص: 4 تسجيلات سليمة فقط >- نضمن تسجيلاً واحداً على الأقل في كل قسم ليكون كل صنف قابلاً للتقييم.

١٠. اختلال توازن الأصناف - القضية الجوهرية

- ▶ 4 تسجيلات سليمة مقابل ~60 تسجيل معطوب.
- ▶ التدريب الساذج >- النموذج يتنبأ "معطوب" دائماً: "دقة" 80% لكن كشف صفري للسليم.
- ▶ الحل: خفض عينة الأغلبية في التدريب/التحقق، وإبقاء الاختبار طبيعياً.
- ▶ نُبلِّغ الدقة المتوازنة و macro-F1، لا الدقة الخام.

١١. بنية الشبكة العصبية الالتفافية

224x224x3

Pool >- Conv128 >- Pool >- Conv64 >- Pool >- Conv32 >-
Softmax >- Dense128 >- Dropout(0.5) >- Flatten >-

► المُحسَّن، Adam خسارة الإنتروبيا المتقاطعة، إيقاف مبكر، تعزيز بيانات.

► نموذج الدمج (fusion): فرعان (تيار + اهتزاز) >- تجميع متوسط عام >- دمج >- طبقة كثيفة.

٠١٢. النتائج - بيانات حقيقية

القناة	الموازنة الدقة	macro-F1	السليم استدعاء	العطل استدعاء
الاهتزاز	1.00	1.00	1.00	1.00
(تيار+اهتزاز) الدمج	0.88	0.76	1.00	0.75
التيار	0.69	0.49	1.00	0.37

تسجيلات محجوزة للاختبار، التمييز: سليم مقابل عطل بين اللغات.

١٣. مصفوفات الالتباس



٠١٤ التحليل

- ▶ الاهتزاز « التيار لكشف العطل بين اللفات - متوقع فيزيائياً (الاهتزاز يستجيب مباشرة، و FOC يُخذ بصمة التيار).
- ▶ الدمج يتفوق على التيار وحده لكن ليس على الاهتزاز وحده.
- ▶ اختيار المقياس مهم: الدقة المتوازنة كشفت انهيار صنف الأغلبية الذي تُخفيه الدقة الخام.

١٥. تجارب التحسين

- ▶ الموازنة تمنع انهيار الأغلبية (استدعاء السليم للتيار $0.00 \rightarrow 1.00$).
- ▶ حجم الصورة: يُحسّن التيار تدريجياً ($-0.68 < 0.76$ من 96 إلى 224)؛ الاهتزاز مُشبع.
- ▶ منحنى التعلم: الاهتزاز يكفيه ~46 صورة؛ التيار ثابت ~0.70 مهما زادت البيانات $\rightarrow$ القيد جودة الإشارة لا كميتها.

١٦. القيود

- ▶ 4 تسجيلات سليمة فقط -> النتيجة المثالية للاهتزاز لا تستبعد تماماً تعلّم “هوية التسجيل”.
- ▶ إزالة المغنطة والحمل الزائد اصطناعية فقط.
- ▶ مقارنة الدمج إرشادية لا مضبوطة بدقّة.

١٧. الخلاصة والعمل المستقبلي

- ▶ منظومة CNN + scalogram قابلة للتكرار تكشف الأعطال بين اللفات؛ الاهتزاز يبلغ دقة متوازنة 1.00 على تسجيلات محجوزة.
- ▶ مستقبلاً: تسجيلات مستقلة أكثر؛ مجموعة دمج متعددة القنوات متزامنة؛ تصنيف حسب الشدة؛ التفسيرية؛ (Grad-CAM) النشر اللحظي داخل المُشغّل.

شكراً لكم

أسئلتكم؟

الشفرة والبيانات والتقارير الكامل:

github.com/molhamfetnah/pmsm-fault-diagnosis-cnn-scalogram